

# 机器学习

## 作业四

### 一. (30 points) 随机森林的原理

集成学习是一种通用技术，通过将多个不同模型的预测结果结合起来，以平均值或多数投票的方式生成单一预测，从而有效应对过拟合问题。

1. 考虑一组互不相关的随机变量  $\{Y_i\}_{i=1}^n$ ，其均值为  $\mu$ ，方差为  $\sigma^2$ 。请计算这些随机变量平均值的期望和方差，给出计算过程。提示：在集成方法的背景下，这些  $Y_i$  类似于分类器  $i$  所作的预测。(5 points)

2. 在第 1 小问中，我们看到对于不相关的分类器，取平均可以有效减少方差。尽管现实中的预测不可能完全不相关，但降低决策树之间的相关性通常能减少最终方差。现在，重新考虑一组具有相关性的随机变量  $\{Z_i\}_{i=1}^n$ ，其均值为  $\mu$ ，方差为  $\sigma^2$ ，每个  $Z_i \in \mathbb{R}$  为标量。假设对任意  $i \neq j$ ， $\text{Corr}(Z_i, Z_j) = \rho$ 。提示：如果你不记得相关性与协方差之间的关系，请回顾你的概率论等课程内容。

- 请计算随机变量  $Z_i$  平均值的方差，以  $\sigma$ 、 $\rho$  和  $n$  为变量表示，给出计算过程。(5 points)
- 当  $n$  非常大时，会发生什么？这对于取平均的潜在有效性说明了什么？(……如果  $\rho$  很大 ( $|\rho| \approx 1$ ) 会怎样？……如果  $\rho$  非常小 ( $|\rho| \approx 0$ ) 又会怎样？……如果  $\rho$  处于中等水平 ( $|\rho| \approx 0.5$ ) 呢？) 无需严格推导——基于你得出的方差公式，用定性分析进行讨论即可。(6 points)

3. Bagging 是一种通过随机化从同一数据集生成多个不同学习器的方法。给定一个大小为  $n$  的训练集，Bagging 会通过有放回抽样生成  $T$  个随机子样本集，每个子样本集大小为  $n'$ 。在每个子样本集中，一些数据点可能会被多次选中，而另一些可能完全未被选中。当  $n' = n$  时，大约 63% 的数据点会被选中，而剩下的 37% 被称为袋外样本点 (Out-of-Bag, OOB)。

- 为什么是 63%？提示：当  $n$  很大时，某个样本点未被选中的概率是多少？请只考虑在任意一个子样本集中（而不是所有  $T$  个子样本集）未被选中的概率。(7 points)
- 关于决策树的数量  $T$ 。集成中的决策树数量通常需要在运行时间和降低方差之间进行权衡（典型值范围从几十到几千棵树）。而子样本大小  $n'$  对运行时间的影响较小，因此选择  $n'$  时主要考虑如何获得最优预测结果。虽然常见实践是设置  $n' = n$ ，但这并非总是最佳选择。你会如何建议我们选择超参数  $n'$ ？(7 points)

## 二. (20 points) 随机森林的实现

在本题中，你将实现决策树和随机森林，用于在以下两个数据集上进行分类：1) 垃圾邮件数据集，2) 泰坦尼克号数据集（用于预测这场著名灾难的幸存者）。数据已随作业提供。

为方便起见，我们提供了初始代码，其中包括预处理步骤和部分功能的实现。你可以自由选择使用或不使用这些代码来完成实现。

```
1 """
2 注意：
3 1. 这个框架提供了基本的结构，您需要完成所有标记为 'pass' 的函数。
4 2. 记得处理数值稳定性问题，例如在计算对数时避免除以零。
5 3. 在报告中详细讨论您的观察结果和任何有趣的发现。
6 """
7 from collections import Counter
8
9 import numpy as np
10 from numpy import genfromtxt
11 import scipy.io
12 from scipy import stats
13 from sklearn.tree import DecisionTreeClassifier, export_graphviz
14 from sklearn.base import BaseEstimator, ClassifierMixin
15 from sklearn.model_selection import cross_val_score
16 import pandas as pd
17 from pydot import graph_from_dot_data
18 import io
19
20 import random
21 random.seed(246810)
22 np.random.seed(246810)
23
24 eps = 1e-5 # a small number
25
26 class BaggedTrees(BaseEstimator, ClassifierMixin):
27
28     def __init__(self, params=None, n=200):
29         if params is None:
30             params = {}
31         self.params = params
32         self.n = n
33         self.decision_trees = [
34             DecisionTreeClassifier(random_state=i, **self.params)
35             for i in range(self.n)
36         ]
37
38     def fit(self, X, y):
```

```
39     # TODO
40     pass
41
42     def predict(self, X):
43         # TODO
44         pass
45
46
47 class RandomForest(BaggedTrees):
48
49     def __init__(self, params=None, n=200, m=1):
50         if params is None:
51             params = {}
52         params['max_features'] = m
53         self.m = m
54         super().__init__(params=params, n=n)
55
56
57 class BoostedRandomForest(RandomForest):
58     # OPTIONAL
59     def fit(self, X, y):
60         # TODO
61         pass
62
63     def predict(self, X):
64         # TODO
65         pass
66
67
68 def preprocess(data, fill_mode=True, min_freq=10, onehot_cols=[]):
69     # Temporarily assign -1 to missing data
70     data[data == b''] = '-1'
71
72     # Hash the columns (used for handling strings)
73     onehot_encoding = []
74     onehot_features = []
75     for col in onehot_cols:
76         counter = Counter(data[:, col])
77         for term in counter.most_common():
78             if term[0] == b'-1':
79                 continue
80             if term[-1] <= min_freq:
81                 break
82             onehot_features.append(term[0])
83             onehot_encoding.append((data[:, col] == term[0]).astype(float))
84         data[:, col] = '0'
85     onehot_encoding = np.array(onehot_encoding).T
```

```
86     data = np.hstack(  
87         [np.array(data, dtype=float),  
88          np.array(onehot_encoding)]  
89     )  
90     # Replace missing data with the mode value. We use the mode instead of  
91     # the mean or median because this makes more sense for categorical  
92     # features such as gender or cabin type, which are not ordered.  
93     if fill_mode:  
94         # TODO  
95         pass  
96  
97     return data, onehot_features  
98  
99  
100 def evaluate(clf):  
101     print("Cross validation", cross_val_score(clf, X, y))  
102     if hasattr(clf, "decision_trees"):  
103         counter = Counter([t.tree_.feature[0] for t in clf.decision_trees])  
104         first_splits = [  
105             (features[term[0]], term[1]) for term in counter.most_common()  
106         ]  
107         print("First splits", first_splits)  
108  
109  
110 if __name__ == "__main__":  
111     dataset = "titanic"  
112     # dataset = "spam"  
113     params = {  
114         "max_depth": 5,  
115         # "random_state": 6,  
116         "min_samples_leaf": 10,  
117     }  
118     N = 100  
119  
120     if dataset == "titanic":  
121         # Load titanic data  
122         path_train = 'datasets/titanic/titanic_training.csv'  
123         data = genfromtxt(path_train, delimiter=',', dtype=None)  
124         path_test = 'datasets/titanic/titanic_testing_data.csv'  
125         test_data = genfromtxt(path_test, delimiter=',', dtype=None)  
126         y = data[1:, 0] # label = survived  
127         class_names = ["Died", "Survived"]  
128  
129         labeled_idx = np.where(y != b'')[0]  
130         y = np.array(y[labeled_idx], dtype=float).astype(int)  
131         print("\n\nPart (b): preprocessing the titanic dataset")  
132         X, onehot_features = preprocess(data[1:, 1:], onehot_cols=[1, 5, 7, 8])
```

```
133     X = X[labeled_idx, :]
134     Z, _ = preprocess(test_data[1:, :], onehot_cols=[1, 5, 7, 8])
135     assert X.shape[1] == Z.shape[1]
136     features = list(data[0, 1:]) + onehot_features
137
138     elif dataset == "spam":
139         features = [
140             "pain", "private", "bank", "money", "drug", "spam", "prescription",
141             "creative", "height", "featured", "differ", "width", "other",
142             "energy", "business", "message", "volumes", "revision", "path",
143             "meter", "memo", "planning", "pleased", "record", "out",
144             "semicolon", "dollar", "sharp", "exclamation", "parenthesis",
145             "square_bracket", "ampersand"
146         ]
147         assert len(features) == 32
148
149         # Load spam data
150         path_train = 'datasets/spam_data/spam_data.mat'
151         data = scipy.io.loadmat(path_train)
152         X = data['training_data']
153         y = np.squeeze(data['training_labels'])
154         Z = data['test_data']
155         class_names = ["Ham", "Spam"]
156
157     else:
158         raise NotImplementedError("Dataset %s not handled" % dataset)
159
160     print("Features", features)
161     print("Train/test size", X.shape, Z.shape)
162
163     # Decision Tree
164     print("\n\nDecision Tree")
165     dt = DecisionTreeClassifier(max_depth=3)
166     dt.fit(X, y)
167
168     # Visualize Decision Tree
169     print("\n\nTree Structure")
170     # Print using repr
171     print(dt.__repr__())
172     # Save tree to pdf
173     graph_from_dot_data(dt.to_graphviz())[0].write_pdf("%s-basic-tree.pdf" % dataset)
174
175     # Random Forest
176     print("\n\nRandom Forest")
177     rf = RandomForest(params, n=N, m=np.int_(np.sqrt(X.shape[1])))
178     rf.fit(X, y)
179     evaluate(rf)
```

```
180
181 # Generate Test Predictions
182 print("\n\nGenerate Test Predictions")
183 pred = rf.predict(Z)
```

Listing 1: 随机森林模型接口

1. 请参考以上模板实现随机森林算法。你也可以选择不参考模板，自行实现，但是不允许使用任何现成的随机森林实现。不过你可以使用库中提供的单棵决策树实现（我们在模板代码中使用了 `sklearn.tree .DecisionTreeClassifier`）。如果使用模板代码，你主要需要实现随机森林继承的超类，即 `bagged trees` 的实现，它会基于不同的数据样本创建并训练多棵决策树。完成后，请在模板中补充上缺失的部分。(5 points)

2. 不需要长篇大论，每个问题用 1-2 句话回答即可：(5 points)

- 你是如何处理分类特征和缺失值的？
- 你是如何实现随机森林的？
- 你是否采用了特殊的方法加速训练？（回答“没有”也是可以的。）
- 还有什么特别棒的功能你实现了吗？（回答“没有”也是可以的。）

3. 对于这两个数据集，请分别训练一棵决策树和一个随机森林，并报告它们的训练准确率和测试准确率。你需要报告 8 个数字（2 个数据集 × 2 个分类器 × 训练/测试）。(5 points)

4. 决策树和随机森林的决策分析。(5 points)

- 对于决策树，选择来自每个类别（垃圾邮件和正常邮件）的一条数据点，列出决策树为对其分类所做的分裂（即，在哪个特征上以及该特征的哪个值上进行分裂）。以下是一个示例：

1. ('hot')  $\geq 2$

2. ('thanks')  $< 1$

3. ('nigeria')  $\geq 3$

4. 因此这封邮件是垃圾邮件。

1. ('budget')  $\geq 2$

2. ('spreadsheet')  $\geq 1$

3. 因此这封邮件是正常邮件。

- 对于随机森林，找出并列树根节点处最常见的分裂。例如：

1. ('viagra')  $\geq 3$  (20 trees)
2. ('thanks')  $< 4$  (15 trees)
3. ('nigeria')  $\geq 1$  (5 trees)

### 三. (20 points) 聚类理论

聚类是一种无监督学习任务，其核心是根据数据样本之间的相似性（通常由距离度量定义）将数据分成若干个簇。常用聚类算法如  $k$ -均值和 DBSCAN 都需要特定的距离度量和超参数设置。以下问题围绕距离度量、目标函数、以及超参数设置展开：

1. 在聚类算法中，距离度量是衡量样本间相似性的基础，选择合适的距离度量对聚类效果有显著影响（5 points）。

(a) 给定样本  $x = (x_1, x_2, \dots, x_d)$  和  $y = (y_1, y_2, \dots, y_d)$ ，分别写出以下三种常见距离度量的数学公式：

- 欧几里得距离
- 曼哈顿距离
- 余弦相似度（将其转换为距离形式）

(b) 在以下场景中，分析哪种距离更适合使用，并简要说明原因：

- 场景 1：高维稀疏特征向量（如文本数据的 TF-IDF 表示）
- 场景 2：二维几何分布数据（如图像中的空间点分布）

2.  $k$ -均值聚类的目标函数与迭代过程， $k$ -均值聚类的目标是最小化以下目标函数（10 points）：

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

其中， $C_i$  表示第  $i$  个聚类簇， $\mu_i$  为第  $i$  个簇的中心。

(a) 推导在分配样本点到最近的簇中心时，为什么目标函数  $J$  会减少。

(b) 推导为什么更新簇中心为簇内样本点的均值时，目标函数  $J$  会减少。

(c)  $k$ -均值的超参数  $k$  对结果有何影响？

- 如果  $k$  设置过大或过小，分别可能会导致什么问题？

- 提出一种确定  $k$  的方法，并解释其原理。
3. 密度聚类（如 DBSCAN）依赖以下两个超参数（5 points）：
- $\epsilon$ （邻域半径）：定义一个点的邻域范围。
  - MinPts（核心点的最小邻域点数）：定义核心点的密度阈值。
- (a) 核心点、边界点和噪声点的定义是什么？它们在聚类中的作用分别是什么？
- (b) 如果  $\epsilon$  和 MinPts 设置不当，可能会出现哪些问题？
- $\epsilon$  过大或过小
  - MinPts 过大或过小
- (c) 为什么 DBSCAN 不需要预先指定聚类簇的数量  $k$ ？这对实际应用有什么优势？

## 四. (30 points) 聚类实战

使用商场客户数据集 (Mall Customer Dataset) 完成客户分群分析。该数据集包含客户的年龄 (Age)、年收入 (Annual Income) 和消费积分 (Spending Score) 等特征。你需要通过实现和优化聚类算法来完成客户画像分析。数据随作业提供。

为方便起见，每小題我们提供了部分初始代码，其中包括预处理步骤和部分功能的实现。你可以自由选择使用或不使用这些代码来完成实现。

```
1 import pandas as pd
2 import numpy as np
3 from sklearn.preprocessing import StandardScaler
4
5 # 加载数据
6 def load_mall_data():
7     df = pd.read_csv("Mall_Customers.csv")
8     X = df[['Age', 'Annual Income (k$)', 'Spending Score (1-100)']].values
9     # 数据标准化
10    scaler = StandardScaler()
11    X_scaled = scaler.fit_transform(X)
12    return X_scaled, X, df
```

Listing 2: 数据加载

1. 在不借助外部实现的情况下，手动实现 KMeans 方法（4 points），在数据集上进行聚类，可视化聚类结果（3 points），并解决下列问题（3 points）：



- 如何使用肘部法则确定合适的  $k$  值，绘图说明
- 简单分析每个客户群的特征
- 计算和分析簇内平方和 (inertia)

```
1 class KMeans:
2     def __init__(self, n_clusters=3, max_iters=100):
3         self.n_clusters = n_clusters
4         self.max_iters = max_iters
5         self.centroids = None
6         self.labels = None
7         self.inertia_ = None # 簇内平方和
8
9     def fit(self, X):
10        """
11        实现K-means算法
12        参数:
13            X: shape (n_samples, n_features)
14        返回:
15            self
16        """
17        # TODO: 实现K-means算法
18        # 1. 随机初始化聚类中心
19        # 2. 迭代优化直到收敛
20        pass
21
22    def predict(self, X):
23        """返回每个样本的聚类标签"""
24        pass
25
26 def plot_clusters(X, labels, centroids=None):
27     """绘制聚类结果的散点图"""
28     pass
```

Listing 3: Kmeans 部分实现

2. 基于问题一的实现，我们发现随机初始化可能导致结果不稳定。请实现和分析以下改进：

- 实现 K-means++ 初始化方法 (4 分)
- 实现聚类评估指标 (3 分)：轮廓系数 (Silhouette Score)、聚类稳定性评估
- 对比分析 (3 分)
  1. 比较随机初始化和 K-means++ 的结果差异，可以通过可视化聚类图进行对比
  2. 比较两种方法的稳定性

## 3. 分析初始化对收敛速度的影响

```
1 class KMeansPlusPlus(KMeans):
2     def _kmeans_plus_plus_init(self, X):
3         """实现K-means++初始化方法"""
4         pass
5
6     def compute_silhouette_score(X, labels):
7         """计算轮廓系数"""
8         pass
9
10    def compute_cluster_stability(X, k, n_runs=10):
11        """评估聚类结果的稳定性"""
12        pass
```

Listing 4: Kmeans++ 部分实现

3. 在实际业务中，不同特征的重要性可能不同，且某些客户群可能需要大小相近。请实现带权重和大小约束的改进版本：

- 实现带约束的聚类算法，需要支持特征加权和簇大小约束 (4 points)
- 在以下两个场景下重新进行实验：收入特征权重加倍，限制每个客户群至少包含 20% 的客户，绘制聚类结果 (6 points)

```
1 class ConstrainedKMeans(KMeansPlusPlus):
2     def __init__(self, n_clusters=3, max_iters=100, weights=None, size_constraints=None):
3         """
4         参数:
5             weights: 特征权重向量
6             size_constraints: 每个簇的最小和最大样本数量限制
7         """
8         super().__init__(n_clusters, max_iters)
9         self.weights = weights
10        self.size_constraints = size_constraints
11
12    def _weighted_distance(self, X, centroids):
13        """计算加权欧氏距离"""
14        pass
15
16    def _reassign_clusters(self, X, labels, distances):
17        """在满足大小约束的情况下重新分配样本到簇"""
18        pass
```

Listing 5: 带约束的聚类算法部分实现